

Structured Debate 是否降低大语言模型中的道德偏差？

研究目标

比较 standard single-response 与 structured debate 是否降低模型层 moral framing bias。核心指标为 yes-no bias 与 omission bias，数值越低越好。

核心结论

- 1. DeepSeek 与 Alibaba Qwen3.6 的结果最稳定，在已完成的 Exp2 与 Exp3 中，debate 均降低了两类 bias。
- 2. Qwen local、Gemma 4 31B 与 Gemini 2.5 Flash 呈现混合结果，说明 debate 的收益具有明显模型依赖性。
- 3. Zhipu GLM-5.1 在 Exp3 中平均 bias 有所下降，但 debate 有效率较低，因此证据强度弱于 DeepSeek 与 Alibaba。

统计摘要

所有已纳入 run 的 framing x prompt ANOVA 交互项均达到显著。
DeepSeek 与 Alibaba Qwen3.6 的统计证据最强，均为 $p < .001$ 。
Zhipu GLM-5.1 / Exp3 也达到显著，但 debate 有效率仅为 0.914。

方法说明

使用原 OSF Exp2/Exp3 刺激材料。
每个 题目 x framing x 条件 使用 56 次重复采样。
仅纳入已完成且已分析的 model-level 结果。

模型	数据集	有效率 Std / Deb	Yes-no Std -> De	Omission Std -> De	结论
DeepSeek	Exp2	1.000 / 1.000	0.423 -> 0.196	0.530 -> 0.256	强支持
DeepSeek	Exp3	1.000 / 1.000	0.833 -> 0.375	0.667 -> 0.467	强支持
Alibaba Qwen3.6	Exp2	1.000 / 1.000	0.155 -> 0.045	0.321 -> 0.286	强支持
Alibaba Qwen3.6	Exp3	1.000 / 1.000	0.557 -> 0.244	0.500 -> 0.220	强支持
Zhipu GLM-5.1	Exp3	1.000 / 0.914	0.726 -> 0.504	0.833 -> 0.417	有前景但稳健性较弱
Qwen local	Exp2	1.000 / 0.999	0.360 -> 0.327	0.027 -> 0.223	混合结果
Gemma 4 31B	Exp2	1.000 / 1.000	0.167 -> 0.012	0.167 -> 0.214	混合结果
Gemini 2.5 Flash	Exp2	1.000 / 0.999	0.036 -> 0.178	0.202 -> 0.107	混合结果